

Inferencia Bayesiana

Lic. Albano Nannini

June 23, 2026

Chapter 1

La probabilidad: Un álgebra subjetivo

En practicamente cualquier proceso que requiera donde podamos utilizar matemática para describir la realidad -ya sea la cuantización de la longitud de una mesa o intentar hacer una predicción sobre el valor de una acción- siempre lo que hacemos es tener que simplificarla lo máximo posible. Pero en esta simplificación queremos mantener la información relevante en lo que respecta a las conclusiones que pretendemos sacar. Si medimos una mesa, pensamos a la distancia como la distancia de un borde a otro. En este contexto, bajo ningún concepto uno debería medir la distancia entre cada uno de los átomos que componen la el borde la tabla de la mesa¹.

Esta simplificación viene de la mano de elegir alguna estructura algebraica que describa lo que necesitamos y que contenga toda la información que sea relevante en la fenomenología que estemos analizando. En el caso de la longitud de la mesa, la estructura que vamos a tomar son los reales $\mathbb{R}$, aunque también podríamos tomar los reales positivos². Pero no solo vamos a pretender que la estructura sea capaz de describir el estado de algo, también pretendemos que los elementos estén relacionados unos con otros. De nada nos serviría si cada número real estuviera desconexo y desordenado de los demás. No es una imagen útil pensar a los números como dispersos en un espacio como si lo es pensarlos en una recta. Este ordenamiento gráfico no lo podemos hacer con cualquier

¹Léase la paradoja de la línea de costa

²¿Por qué no podríamos tomar a los racionales $\mathbb{Q}$?

conjunto -no al menos tan bien motivado como lo podemos hacer con $\mathbb{R}$. Esta gráfica es posible debido a que los reales están estructurados, y su estructura viene de sus operaciones básicas $(+, \cdot)$ y una noción de orden $(<)$. Estas operaciones y noción de orden se definen abstractamente sin que representen algo físico o real.

Básicamente siempre podemos armar conjuntos y estructurarlo con operaciones, relaciones de orden y otras cosas, y por sí mismo este proceso siempre va a tener sentido. Pero el problema es que no necesariamente las estructuras algebraicas resultantes van a representar algo de la realidad. No solo vamos a pretender codificar el estado actual de lo que modelemos, también vamos a pretender que las operaciones estén bien motivados. En el caso de la mesa, las operaciones sobre el conjunto abstracto de los reales coincide con lo que esperaríamos se relacionen las longitudes de mesas combinadas.

En general todo proceso de modelado tiene implícito más o menos los siguientes pasos

1. Simplificación de aquello que queremos modelar. Nos quedamos la información que nos parezca relevante.
2. Elección de una estructura algebraica que codifique aquella información. Pretendemos que esta estructura tenga operaciones que relacionen a sus elementos de una forma que este motivada por como se relacionan aquellos estados de lo que estamos modelando.
3. Una vez que ya abstraímos el problema sencillamente confiamos en las operaciones. Manipulamos algebraicamente las expresiones -o lo que sea que tengamos- sin estar pensando en que representan en cada paso intermedio hasta que llegamos a las conclusiones que estabamos buscando en un principio.

Por supuesto, uno tiene que elegir lo que modela y cómo en base a las conclusiones que pretende sacar. Además confiar ciegamente en los resultados puede ser un poco iluso porque el modelo puede fallar -sin mencionar que podemos tener errores. Por lo tanto cierto grado de intuición sobre lo que estamos modelando suele ser muy útil para ver si los resultados son directamente descartables.

Otros ejemplos en niveles crecientes de abstracción:

- Si queremos modelar cantidades de personas la estructura algebraica más ajustada serían los números naturales $\mathbb{N}$. Cada posible cantidad de número de personas tiene un número asociado y sus operaciones están bien motivadas. La suma representa cuantas personas

tendría un grupo que consista en la unión de dos subgrupos de personas. Y por supuesto, la multiplicación sería la unión de muchos grupos con la misma cantidad de personas.

- Si quisieramos modelar la distancia que recorre un taxi la distancia euclídea no nos sería de mucha ayuda pues es la distancia que recorrería una paloma, no un auto. Para esto existe una estructura algebraica que abstrae la noción de distancia llamada espacios métricos. Esta estructura consiste en un conjunto $\mathbb{X}$ y una operación $m : \mathbb{X} \times \mathbb{X} \rightarrow \mathbb{R}$ que satisface ciertas propiedades que debería satisfacer una distancia como mínimo.
- Un ejemplo poco discutido es la abstracción de la temperatura como un número real. En este caso la operación suma no está tan bien definida como uno esperaría dado que el resultado de la suma va a depender de las unidades que estemos utilizando y esto lleva a paradojas (no es lo mismo sumar en Kelvin que en Celcius porque tienen el origen desplazado). Uno se podría preguntar en contraposición por qué deberíamos sumar temperaturas. La realidad es que esta suma no tiene significado desde el punto de la vista de la teoría de termodinámica, de hecho lo que si tiene mucho más sentido -y por tanto es independiente de unidades- es la diferencia de temperaturas.

Uno podría interesarse en la suma si lo que pretende es promediarlas por ejemplo. Justo en el ejemplo en cuestion, el promedio coincidirá independiente de las unidades utilizadas porque están relacionadas de forma lineal -aunque no homogeneamente. Pero el promedio no tiene por qué ser independiente de cualquier cambio de coordenadas, de hecho frente a cambios de coordenadas más generales en ningún contexto lo es. Pero sea como sea, lo que uno pretende del promedio en estadística al final es una medida de centralidad de un conjunto de datos.

- Uno puede conceptualizar a una imagen digital en blanco y negro con n pixeles de ancho y m de largo como una matriz real de $n \times m$. En principio, para guardar la imagen en la computadora uno no necesita definir mayores operaciones. Sin embargo es de utilidad es asignarle operaciones al conjunto de matrices para la realización de ciertas aplicaciones -como *computer vision*. Operaciones de mucha utilidad son las dadas por la estructura de los espacios vectoriales, donde definimos las operaciones suma de matrices y producto por

un número. Otras operaciones útiles son el producto punto, las convoluciones, etc. De hecho, la estructura de los espacios vectoriales es de gran utilidad en múltiples circunstancias -de momento es casi omnipresente en Machine Learning.

En particular, la estructura algebraica protagonista de este curso es la de “*Espacio de probabilidad*”. Esta estructura fue desarrollada por Andréi Kolmogorov en 1933 con lo que en la literatura se suele denominar a este conjunto axiomático “Axiomas de Kolmogorov” [**kolmogorov1933grundbegr**, **kolmogorov1956foundations**]. El gran logro de Kolmogorov fue formalizar en una teoría basada en conjuntos -que son el fundamento de las matemáticas desde el siglo pasado- el lenguaje de probabilidad que se viene desarrollando desde el siglo XVIII.

Gran parte de estas estructuras algebraicas son más difíciles de entender que lo que modelan y la ganancia está en que una vez entendida la estructura podemos manejarnos en el nivel de abstracción que nos quede cómodo. Pero en teoría de probabilidad eso es muy diferente. De alguna forma, el algebra de la probabilidad codifican matemáticamente nuestra información, lo que es mucho más abstracto que la longitud de una mesa, la cantidad de personas de un grupo, la distancia que recorre un taxi, una temperatura o una imagen en blanco y negro. De hecho, hay muchas interpretaciones de lo que significa “la probabilidad de algo” y eso es lo que estudiaremos a continuación.

1.1 Los espacios de probabilidad

Definición 1 *Un espacio muestral $\mathbb{X}$ es el conjunto de todos los resultados posibles de un experimento. Un evento es un subconjunto de este.*

Definición 2 *Dado un espacio muestral $\mathbb{X}$, un espacio de eventos³ es un conjunto Σ compuesto de eventos del muestral que satisface las siguientes propiedades*

$$\bullet \quad \mathbb{X} \in \mathbb{B}; \quad (1.1)$$

$$\bullet \quad A \in \Sigma \implies A^c \in \Sigma; \quad (1.2)$$

³o σ -álgebra o álgebra de Boole.

- Dada una familia de eventos A_i con $i \in I$,

$$A_i \in \Sigma \implies \bigcup_{i \in I} A_i \in \Sigma. \quad (1.3)$$

Definición 3 Dado un espacio muestral $\mathbb{X}$, un espacio de eventos asociado Σ y una función $P : \Sigma \rightarrow \mathbb{R}$ que llamaremos **función de probabilidad**. Se dice que la terna $(\mathbb{X}, \Sigma, P)$ forman un **espacio de probabilidad** si la función P satisface los siguientes axiomas:

-

$$P(\mathbb{X}) = 1; \quad (1.4)$$

- $\forall A \in \Sigma$,

$$P(A) \geq 0; \quad (1.5)$$

- Dada una familia de eventos disjuntos A_i con $i \in I$,

$$P\left(\bigcup_{i \in I} A_i\right) = \sum_{i \in I} P(A_i). \quad (1.6)$$

Ya definidas las propiedades fundamentales de la función de probabilidad, se puede entender por qué se eligieron aquellos axiomas para el conjunto de eventos. Son sencillamente aquellos que hacen que siempre tengan sentido los axiomas -o el álgebra- de la función de probabilidad.

Otras definiciones y conceptos básicos relevantes que deberían estar claros a esta altura son los de **variable aleatoria**, **valor medio**, **momentos**, **distribuciones discretas y continuas**. Y aunque estos sean conceptos probablemente más sofisticados del que vamos a debatir a continuación, lo cierto es que la siguiente definición es la reina de esta de materia:

Definición 4 Dado un espacio de probabilidad $(\mathbb{X}, \Sigma, P)$ y dos eventos $A, B \in \Sigma$ tal que $P(B) \neq 0$, se define la **probabilidad de A dado B** como

$$P(A|B) = \frac{P(A, B)}{P(B)}. \quad (1.7)$$

Y de ella sale trivialmente el gran teorema que le da el nombre a la materia:

Teorema 1 *Dado un espacio de probabilidad $(\mathbb{X}, \Sigma, P)$ y dos eventos $A, B \in \Sigma$ con probabilidades no nulas vale que*

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)} \quad (1.8)$$

Como dijimos, si nosotros nos inventamos un conjunto con operaciones que satisfacen ciertas normas, las sigue y listo. No nos tenemos que gastar en justificar por qué elegimos lo que elegimos. El problema es que no pretendemos armar una estructura algebraica y listo. Lo que queremos lograr es una manera de cuantificar lo que entendemos por probabilidad. Y esto es particularmente difícil no solo de un lado matemático, sino de uno filosófico, pues nadie tiene muy claro que es lo que entendemos por probabilidad y ahí nacen muchas de sus interpretaciones que terminan justificando esta elección de axiomas.

1.2 Interpretaciones de la probabilidad.

1.2.1 Interpretación clásica

Esta interpretación es un producto de la motivación de donde nace la teoría de probabilidad, mucho antes de su axiomatización. Blaise de Pascal y Pierre de Fermat son considerados padres de esta teoría por formalizar matemáticamente esta primera interpretación. Y el problema que querían abordar era entender cuando convenía o no apostar⁴. Entonces, como el azar de la mayoría de juegos de apuestas depende del resultado de una tirada de cartas o de dados, hay cierta simetría entre todos los resultados posibles. De allí nace el “*principio de Laplace*” que indica que:

“Si un conjunto de resultados es posible y no hay razones adicionales para suponer una mayor ocurrencia de uno de ellos entonces la probabilidad de cada resultado debe ser la misma”

Esto nos lleva a una de las formulas más típicas de teoría de probabilidad,

$$\text{Probabilidad de un caso favorable} = \frac{\text{Número de casos favorables}}{\text{Número de casos totales}}. \quad (1.9)$$

Nuevamente, en el contexto de juegos de azar que incluyen dados y cartas esta interpretación es sólida debido a que es relativamente sencillo

⁴Problemática fundamental de la existencia humana

entender a los eventos como uniones finitas de casos posibles simétricos. Una ventaja de esta interpretación es que reduce el calculo de probabilidades al de combinatoria. Otra es que si partimos de una definición de probabilidad basada exclusivamente en la ecuación (1.2.3) entonces podríamos motivar los axiomas de Kolmogorov y la definición de probabilidad condicional de forma muy sencilla. Tampoco se podría negar su valor práctico y didáctico.

Esta interpretación tiene el problema que es bastante rígida cuando queremos ampliar el marco de uso de las probabilidades. Por ejemplo si quisieramos hablar de un dado cargado ya no podríamos dividir al espacio en casos simétricos. Otro problema también aparecería cuando quisieramos hablar de probabilidad en el caso continuo, donde la probabilidad no recae sobre puntos del espacio muestral sino que la información se codifica en una densidad de probabilidad.

1.2.2 Interpretación frequentista

La siguiente interpretación fue la hegemónica del siglo XX. Supongamos que cierto contexto da pie a que suceda, o no, un evento A . La interpretación frequentista indica que la probabilidad de A debe ser

$$P(A) = \frac{\text{Número de veces que sucedió } A}{\text{Número de veces que pudo haber sucedido } A}, \quad (1.10)$$

cuando el número de veces que pudo haber sucedido A tiende a infinito.

La gran ventaja de esta interpretación es que la probabilidad en este contexto es objetiva y bien medible, casi que desprecia la abstracción y pone en la poltrona resultados de experimentos que se pueden repetir.

Frente a la interpretación de probabilidad clásica tiene grandes ventajas. Permite extender el marco teórico a situaciones más amplias donde el espacio muestral no se reduce a eventos equiprobables y podemos afrontar un rango de problemas más amplio que ahora puede incluir dados cargados y distribuciones continuas.

Esta interpretación va a tener un problema teóricamente grave, que es por supuesto, el problema de la repetición. En primer lugar es claro que nunca se tienen infinitas repeticiones de un mismo experimento o contexto. Pero ignorando esto -que hay que admitir puede interpretarse como una crítica un tanto superflua- y considerando que aproximamos el límite por la situación estacionaria a la que se puede -o no- llegar después de hacer muchas repeticiones. Y aún así tenemos dos problemas:

¿Qué hacemos con experimentos que nos se pueden repetir? y ¿Qué es exactamente repetir un experimento?

Esta ya no es una crítica superflua, en muchas situaciones vamos a querer asignar probabilidades a situaciones que pueden ocurrir o no hacerlo una única vez:

- ¿Mañana llueve o no?
- Si mañana cae un meteorito;
- Si el Coronel Mostaza fue el que asesinó a el Dr. Black;
- El ganador de las elecciones en 2027 y
- un largo etc.

Más aún, en la mayor parte de lo fenómenos que vamos a querer estudiar y podamos analizar mediante su repetición la azarocidad va a depender específicamente de aquellos aspectos que no vamos a poder repetir. Por ejemplo, de tirar una moneda si repetimos exactamente las mismas condiciones iniciales que incluyen cómo apoyamos la moneda en el dedo, como lo movemos para arrajorla al aire, el estado de partícula de aire que choca contra ella y el momento y modo de agarre entonces vamos a obtener el mismo resultado. Y esto no es meramente teórico, según las leyes de la mecánica clásica todos los fenómenos a los que nos enfrentamos son deterministas⁵.

Esta cuestión acerca de la repetibilidad de los experimentos lleva a considerar que hay dos tipos de fenomelogías en juego en la realización experimental repetida: una contextual en la vamos a volcar la repetibilidad del experimento y otra ruidosa donde van a estar todas aquellas cosas de las que no tenemos información. Aunque por supuesto, su diferencia excede el control el experimental y recae en hace suposiciones sobre el ruido del cual no se tiene ningún control. Por lo que este último en general escondé toda aquella información no accesible.

Esta interpretación llega a los axiomas de Kolmogorov y la probabilidad condicional mediante considerar los límites asintóticos de los eventos.

1.2.3 Interpretación bayesiana

Rondan los 1740s y el filosofo David Hume publica un famoso ensayo filosófico alegando que es más probable que un supuesto testigo mienta

⁵Leasé acerca del demonio de Laplace

a que haya realmente haya ocurrido un milagro. En respuesta a esto el reverendo Thomas Bayes va a defender la racionalidad de la fé armando y escribiendo un marco matemático que muestra como nueva evidencia debe modificar nuestras creencias actuales. Esto se va a codificar matemáticamente como su gran teorema aunque no sea él que va a publicar su propio trabajo, sino que lo hará su amigo Richard Price luego de su muerte, después de que Laplace haya llegado a el de forma independiente.

Hoy en día, no se le adjudica la demostración del teorema de Bayes a Bayes, sino a Laplace. Pero la interpretación de Bayes es lo que lo hace algo diferente, motiva a la probabilidad como una cuantificación de las creencias y la probabilidad condicional a la actualización racional de estas frente a nueva evidencia. Digamos que el enunciado clave de la interpretación bayesiana de la probabilidad es que

“La probabilidad de cierto evento A es subjetiva e indica el grado de certeza que tenemos acerca de A ”

El gran problema que va a tener esta interpretación es que la probabilidad va a dejar de ser algo objetivo y facilmente medible y solo va a caracterizar nuestros grados de creencias sobre ciertos resultados. Pero de hecho, este fue un problema que siempre tuvimos, siempre había que realizar cierta hipótesis sobre la fenomenología que estamos estudiando y lo que nos posibilitaban otras interpretaciones era barrer esta necesidad hipotesis debajo de la alfombra.

De hecho, en este contexto se entiende mejor a que nos referimos exactamente con repetibilidad de experimentos de la interpretación frecuentista. Hay cierto contexto que nos brinda cierta información y sobre esto hay fenomenología sobre la cual no entendemos su comportamiento. Sujeto a la información que tenemos vamos a tener cierto grado de certeza sobre los posibles resultados y la repetición esta en que volvamos a realizar el experimento con la misma información.

El autor Cox va a intentar llevar aún más lejos de lo esperado el campo de acción de la probabilidad y va a armar aparte una estructura matemática que denomina plausibilidad. En esta va a pedir ciertas propiedades de lo que uno esperaría que respete una noción cuantitativa la certeza sobre eventos y eventualmente va a llegar con demostraciones a la noción de probabilidad kolmogoroviana con su definición de probabilidad condicional -que indica como actualizar nuestras creencias frente a evidencia. De hecho va a hacer que la probabilidad también se defina sobre proposiciones lógicas[cox1961algebra]. Sobre su camino va

a seguir el físico norteamericano Edwin Thompson Jaynes en una de las más celebres obras de la teoría de probabilidad “Probability Theory: The Logic of Science” [jaynes2003probability].

Esta interpretación es particularmente útil en el área de ciencia de datos, particularmente porque vamos a pensar a las distribuciones de probabilidad como resultado de actualizar nuestras creencias frente a nueva evidencia aplicando el teorema de Bayes. De hecho, como vamos a debatir a continuación la inferencia tiene más sentido en un contexto bayesiano, debido a que la repetición experimental es a efectos prácticos imposible y vamos a necesitar una teoría de probabilidad subjetiva -en base a la información con la que se cuenta- y no objetiva -como brindaría la interpretación frecuentista.

Por supuesto, hay veces que la repetición de un experimento tiene muy bien caracterizadas los impactos del contexto y el ruido por lo que la repetición se vuelve algo viable y analizable desde la teoría de probabilidad. En este contexto e interpretación las probabilidades todavía representarían un grado de creencia sobre los resultados. Pero aún así, de hacer una afirmación científica reportar un grado de creencia no es suficiente puesto que queremos hacer predicciones. Lo que nos lleva a pretender aparte, que la probabilidad coincida simultáneamente con aquella obtenida por la interpretación frecuentista.

Solo por mencionarlo, el mundo moderno cuenta con una teoría científica que indica que en condiciones iniciales idénticas se pueden obtener resultados diferentes y cuyas predicciones son probabilísticas independiente de nociones de ruido. Este es el caso de la mecánica cuántica, que al ser una teoría científica necesita ser examinada con criterios objetivos para analizar sus predicciones. Más aún considerando que pretende ser una teoría fundamental del universo y la realidad. En este caso se debe volver a interpretar a la probabilidad en el sentido frecuentista, de lo contrario las predicciones de la mecánica cuántica solo serían grados de creencia, lo que pondría en jaque su falseabilidad.

La probabilidad como extensión de la lógica: el empirismo

Como dije en la sección anterior Cox y Jaynes pretenden extender las nociones de probabilidad a la lógica. Y con esto van a lograr enmarcar muchos razonamientos típicos válidos pero que no están contemplados en la lógica.

En el álgebra booleana, se les asigna a ciertas proposiciones el carácter de verdadero o falso aunque también, más conveniente este texto, 1

o 0 respectivamente. Supongamos que tenemos tres proposiciones A , B y $C := A \rightarrow B$. Si A y C resultan ciertas podemos hacer el sigilogismo

$$\frac{\begin{array}{c} A \\ A \rightarrow B \end{array}}{\therefore B}$$

Sin embargo, si B y C son ciertas no podemos asumir que A lo sea. Y está bien que sea así, pero en general si se cumplen estas dos condiciones típicamente aumenta la plausibilidad de A . Sobre esto Jaynes da el siguiente ejemplo en su libro

Supongamos que en una noche oscura, un policía camina por una calle aparentemente vacía. De pronto escucha una alarma de robo, mira al otro lado de la calle, y ve a una joyería con la ventana rota. Luego un caballero llevando una mascara sale gateando a través de la ventana rota cargando una bolsa que resulta estar llena de joyas preciosas. El policía no duda en decidir que el caballero es deshonesto. Pero ¿Por qué proceso él llega a esta conclusión?

Si somos cuidadosos, vemos que el policía no llega mediante lógica booleana o un razonamiento puramente lógico a la conclusión que llega. Si no que, mediante agregar nueva evidencia se va haciendo más plausible que el otro personaje sea en realidad un ladrón.

Esta situación ejemplifica algo muy típico, que es que en general queremos inferir que tan plausible es A a partir de las consecuencias que tiene que si podemos ver directamente. Y como solo contamos con la proposición $A \rightarrow B$, la lógica no alcanza para asumir A en base a B . Otra situación típica es que queremos corroborar una hipótesis (A), de ser cierta la teoría lleva a ciertas conclusiones ($A \rightarrow B$ con valor verdadero). Luego revisamos si es cierto B y de serlo, entonces esto es evidencia de que A es cierta. Nuevamente, la lógica no ampara este sigilogismo y aún así es idea principal detrás del empirismo científico.

Lo que proponen Cox y Jaynes es considerar la plausibilidad normalizada P (o la probabilidad directamente) de A y B . Si Ω es una proposición, su plausibilidad es $P(\Omega)$, de ser cierta $P(\Omega) = 1$ y de ser falsa $P(\Omega) = 0$. A diferencia de la lógica booleana, vamos a permitir valores de lógica intermedios entre 0 y 1.

Con estas nociones vayamos al sigilogismo problemático. Sabemos que $A \rightarrow B$ y se puede escribir matematicamente como

$$P(B|A) = 1, \tag{1.11}$$

pues nuestra plausibilidad de este hecho es segura. Ahora además descubrimos que B es verdadera, con lo que tenemos nueva evidencia y debemos actualizar la plausibilidad de A con el teorema de Bayes,

$$P(A|B) = \frac{P(B|A)}{P(B)}P(A) = \frac{1}{P(B)}P(A). \quad (1.12)$$

Sabiendo que $P(B) \leq 1$, entonces llegamos a la conclusión de que

$$P(A|B) \geq P(A). \quad (1.13)$$

¡Esto implica que frente a la nueva evidencia, gracias al teorema de Bayes y la proposición $A \rightarrow B$, la verosimilitud de B hace que A sea más plausible! Cosa que la lógica a secas no nos alcanzaba.

Entonces esta nueva forma de entender a la probabilidad nos sirve entender una clase muy cotidiana de sigilogismos que en la lógica estaban prohibidos, cambiando la inferencia tradicional por el teorema de Bayes.

1.3 Resumen de la teoría de probabilidad

Con el objetivo de manejar un lenguaje común sobre la teoría de probabilidad y aprovechando a repasar a continuación se dejan las definiciones típicas asociadas al estudio de la probabilidad. La motivación la dejo en mano de cursos anteriores.

Definición 5 *Dado un espacio de probabilidad $(\mathbb{X}, \Omega, P)$, decimos que dos eventos $A, B \in \Omega$ son **independientes** si*

$$P(A, B) = P(A)P(B). \quad (1.14)$$

1.3.1 Variables aleatorias unidimensionales

Definición 6 *Dado un espacio de probabilidad $(\mathbb{X}, \Omega, P)$, una **variable aleatoria** o **RV** -Random Variable- es una función $X : \mathbb{X} \rightarrow \mathbb{R}$.*

Cuando la variable aleatoria sea numérica, vamos a hablar indistintamente del espacio muestral y de sus valores posibles. El objetivo de la variable aleatoria es traducir los resultados de un experimento a un conjunto ordenado. Además también nos va a permitir acceder a eventos de forma más directa.

Definición 7 Dada una variable aleatoria X y una proposición $Q(x)$ que depende del número real x -también podríamos pensarla en una función $Q : \mathbb{R} \rightarrow \{0, 1\}$ - definimos el evento

$$Q(X) = \{x \in \mathbb{R} | Q(x)\}$$

Definición 8 Dada una variable aleatoria X con distribución P , definimos la **distribución acumulada** o **CDF** -Cumulative distribution function- como la función $F : \mathbb{R} \rightarrow \mathbb{R}$ según

$$F(x) = P(X \leq x) \quad (1.15)$$

Variables aleatorias discretas y continuas

Hasta ahora nada de lo que realizamos nos impidió tratar a variables aleatorias discretas y continuas en pie de igualdad. Sin embargo, el cálculo de valores medios ya nos obliga a hacer cierta discriminación.

Dada una variable aleatoria X , si su CDF es una función continua de F , entonces estamos en presencia de lo que se denomina una variable aleatoria continua. En cambio, si la CDF a la variable aleatoria se la denomina discreta.

Definición 9 Sea X una variable aleatoria continua. Se define la **densidad de probabilidad** o **PDF** -Probability Density Function- de X como la función $f : \mathbb{R} \rightarrow \mathbb{R}$ que satisface

$$F(x) = \int_{-\infty}^x f(x) dx. \quad (1.16)$$

Es claro que en los $x \in \mathbb{R}$ donde F sea derivable se satisface

$$F'(x) = f(x) \quad (1.17)$$

en virtud del teorema fundamental del cálculo. Además, típicamente se suele definir a una variable aleatoria continua a partir de su PDF y no de su CFD.

Valores medios y momentos

Definición 10 Dada una variable aleatoria X , con distribución P si es discreta (izquierda) y f si es continua (derecha) se definen:

- Dada una función $h : \mathbb{X} \rightarrow \mathbb{R}$, se define el valor medio de h como

$$\langle h(X) \rangle = \sum_i h(x_i) p(x_i) \quad \langle h(X) \rangle = \int_{-\infty}^{\infty} h(x) f(x) dx \quad (1.18)$$

- Valores medios descatables son

– El valor medio de X , $h(x) = x$,

$$\mu = \sum_i x_i p(x_i) \quad \mu = \int_{-\infty}^{\infty} x f(x) dx; \quad (1.19)$$

– Su varianza, $h(x) = (x - \mu)^2$,

$$\sigma^2 = \sum_i (x_i - \mu)^2 p(x_i) \quad \sigma^2 = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx; \quad (1.20)$$

– El momento de orden n centrado en x_0 , $h(x) = (x - x_0)^n$,

$$m_n(x_0) = \sum_i (x_i - x_0)^n p(x_i) \quad m_n(x_0) = \int_{-\infty}^{\infty} (x - x_0)^n f(x) dx; \quad (1.21)$$

La gracia de obtener los momentos de una distribución de probabilidad es que después los podemos usar para calcular el valor medio de cualquier función analítica,

$$\langle h(X) \rangle = \int h(x) p(x) dx = \int \sum_n \frac{1}{n!} \frac{d^n h}{dx^n}(x_0) (x - x_0)^n p(x) dx \quad (1.22)$$

$$\langle h(X) \rangle = \sum_n \frac{1}{n!} \frac{d^n h}{dx^n}(x_0) m_n(x_0). \quad (1.23)$$

Una buena idea sería elegir x_0 de forma tal que los m_n sean lo más chicos posibles y así poder despreciar términos de mayor orden en la sumatoria.

Chapter 2

Elementos Básicos de la Inferencia Bayesiana

En contraposición al delirio filosófico y algebraico del capítulo anterior arrancamos este con un ejemplo mucho más práctico. Desgraciadamente recién para el final del capítulo lo vamos a poder terminar de resolver. Nos encontramos una moneda en la calle y queremos determinar la probabilidad de que al arrojarla obtengamos una cara.

Ignorando la posibilidad de que caiga de canto, los resultados posibles de arrojarla son seca o cara o, para mayor simplicidad en las cuentas, $\mathbb{X} = \{0, 1\}$. Por lo tanto, podemos modelar la distribución de probabilidad de los resultados como

$$P(x|\mu) = \begin{cases} 1 - \mu & x = 0 \\ \mu & x = 1 \end{cases} \quad (2.1)$$

donde μ es el parámetro de la distribución.

Descripto de esta forma, el problema ahora es intentar inferir el valor de μ que de mínima está entre 0 y 1. En principio, lo que nos interesaría sería hacer varias realizaciones del experimento y con ellas realizar la inferencia. Supongamos que tiramos la moneda N veces y los resultados los vamos guardamos en un vector

$$\mathbf{x} = (x_1, \dots, x_n). \quad (2.2)$$

Ahora, asumiendo independencia entre las tiradas, lo que podemos calcular con la ecuación (2.1) es $P(\mathbf{x}|\mu)$ cuando lo que realmente nos interesa es $P(\mu|\mathbf{x})$, es decir, nuestras expectativas de μ actualizadas a las

mediciones que realizamos. Utilizando el teorema de Bayes,

$$P(\mu|\mathbf{x}) = \frac{P(\mathbf{x}|\mu)}{P(\mathbf{x})}P(\mu). \quad (2.3)$$

La dependencia de esta nueva distribución de probabilidad con $P(\mu)$ es bastante molesta porque requiere tener formalizada una expectativa de μ en ausencia de mediciones. Algunas decisiones posibles serían:

- Agarrar algún estudio de alguien que se haya molestado en hacer un histograma con un millón de monedas. Luego, con un criterio frecuentista, argumentar que nuestras expectativas sobre el parámetro que caracteriza nuestra moneda coincide con la de las monedas usada en el estudio. La gran ventaja de este método es que la distribución de probabilidad μ estaría muy bien argumentada. Su gran problema es que tenemos que encontrar a alguien que se haya molestado en resolver el problema antes que nosotros, lo que no siempre sucede.
- Fijar a dedo una distribución de probabilidad para $P(\mu)$ en base a nuestras expectativas. Esto cae obviamente en una interpretación bayesiana de la probabilidad. De elegir esta opción, sería conveniente tomar una función con la que sea fácil realizar manipulaciones algebraicas.
- Decir $P(\mu)$ es uniforme entre 0 y 1. Por supuesto, esta elección es únicamente un caso particular de la previamente mencionada, pero separado por ser una elección **muy** típica. La gran ventaja de esta asunción es que las cuentas se simplifican mucho y no le damos más probabilidad a ningún parámetro sobre otro. La principal desventaja se encontraría en que estaríamos diciendo que tenemos la misma expectativa de encontrar al parámetro en el intervalo $[0, 0.1]$ que en el $[0.45, 0.55]$ lo que nuestra experiencia dice que es absurdo.

Elijamos lo queelijamos, siempre vamos a tener que hacer una suposición y esa es una lección fundamental de la inferencia bayesiana

Para hacer inferencia siempre vamos a tener que hacer suposiciones. El marco bayesiano puede enmarcar como actualizar nuestras creencias pero para actualizar algo es necesario que exista desde un principio.

2.1 Inferencia de parámetros

Supongamos que tenemos cierto experimento con resultados $x \in \mathbb{X}$. Sabemos que la distribución de probabilidad de x tiene cierta forma que es dependiente de parámetros que no conocemos. A estos parámetros desconocidos los llamamos θ . Al conjunto de posibles parámetros los llamamos Θ . Es decir, tenemos conocimiento de las funciones

$$P(\mathbf{x}|\theta) \quad (2.4)$$

con $\theta \in \Theta$. Nuevamente, la idea es determinar los valores θ de los parámetros mediante realizaciones del experimento. De realizar el experimento N veces guardamos el vector $\mathbf{x} = \{x_1, \dots, x_N\}$.

2.1.1 Términos del teorema de Bayes

Mediante el uso del teorema de Bayes nomenciamos las siguientes cantidades

$$\underbrace{P(\theta|\mathbf{x})}_{\text{Posteriori}} = \frac{\overbrace{P(\mathbf{x}|\theta)}^{\text{Verosimilitud}}}{\underbrace{P(\mathbf{x})}_{\text{Evidencia}}} \underbrace{P(\theta)}_{\text{Priori}}. \quad (2.5)$$

Esta terminología nace de que practicamente en todo problema de inferencia cada término tiene el mismo rol.

- La distribución a priori -o prior- $P(\theta)$: cuantifica nuestro grado de creencia sobre que el parámetro real es θ desde antes de realizar las mediciones. El problema que detallamos anteriormente sobre elegir una priori no es algo que al día de hoy tenga una solución concreta y muchos trabajos científicos enteros se basan en su justificación. Como se comentó previamente, estas dificultades se traducen luego a una elección de priori uniforme, ya que al menos es fácil de manipular algebraicamente.
- La verosimilitud -o likelyhood- $P(\mathbf{x}|\theta)$: cuantifica que tan posible vemos la realización obtenida del experimento sujeta a las mediciones realizadas.
- La posteriori -o posterior- $P(\theta|\mathbf{x})$: cuantifica el grado de creencia sobre los valores de θ actualizadas por las mediciones realizadas.

- La evidencia -o evidence- $P(\mathbf{x})$: nombrada así por ser la probabilidad de aquello que entendemos por la evidencia a favor de una determinación de parámetros sobre otra. En el proceso de inferencia es la parte que menos “arte” tiene, pues se puede calcular utilizando la normalización de la posteriori. Además, es importante notar que este término es independiente del parámetro que se busca determinar.

2.1.2 La naturaleza del espacio donde viven los parámetros

Hasta ahora no aclaramos que si los parámetros θ son discretos o continuos. Tampoco aclaramos si tienen una o varias dimensiones. La razón de esto es que la argumentación para estos tópicos no requiere separar por casos. Sin embargo es útil tener una noción de la naturaleza que podrían tener estos espacios. Algunos ejemplos de la forma que tienen estos espacios pueden ser:

- Si la distribución que sigue x es de Bernoulli -como la moneda-, entonces su único parámetro es μ , lo que hace que el espacio Θ sea el segmento $[0, 1]$
- Si la distribución que sigue que x es una binomial -como la cantidad de veces que obtiene cara luego de tirar una moneda una cantidad fija de veces- los parámetros son n y p siendo la cantidad de veces que se repite el experimento y la probabilidad de éxito de cada uno de ellos. Entonces podemos pensar a Θ como 10 segmentos $[0, 1]$ desconectados, esto es

$$\Theta = [0, 1] \times \mathbb{N} = \{(p, n) | p \in [0, 1], n \in \mathbb{N}\}. \quad (2.6)$$

Pero esto es solo si queremos determinar n y p simultáneamente. De hecho, más típico es conocer el valor de n e intentar determinar el de p . En cuyo caso la naturaleza del espacio de parámetros se reduce a la misma que la de un evento de Bernoulli.

- Si la variable aleatoria X toma valores en una gaussiana sus parámetros deben ser la media y la desviación estandar.
 - Si sabemos la desviación estandar y queremos averiguar la media, el espacio de parámetros sería la recta real,

$$\Theta = \mathbb{R} \quad (2.7)$$

- Si sabemos la media y queremos averiguar la desviación estandar, el espacio de parámetros sería la semirecta positiva de los reales,

$$\Theta = \mathbb{R}^+ \quad (2.8)$$

- Y si quisiéramos determinar ambas simultaneamente,

$$\Theta = \mathbb{R} \times \mathbb{R}^+ \quad (2.9)$$

- Una distribución mucho menos común es la de Von Mises, en esta, los valores que toma x son ángulos de un círculo¹. Es decir $x \in [0, 2\pi]$ y su distribución de probabilidad es

$$P(x|\phi, \kappa) = \frac{1}{2\pi I_0(\kappa)} \exp(\kappa \cos(x - \mu)). \quad (2.10)$$

Supongamos que ya sabemos el valor de κ -que representa algo así como la desviación estandar adaptada a un círculo- y queremos averiguar el valor de μ -que representa la media también adaptada a esta trayectoria. Podríamos tentarnos y decir que $\Theta = [0, 2\pi]$ ya que son los valores posibles de μ y respecto a eso tendríamos razón. El problema es que perderíamos de vista algo muy importante desde el punto de vista de la inferencia. Esto que perderíamos de vista sería la facilidad que tendríamos para distinguir valores de θ con mediciones. Como los μ representan ángulos, entonces $\mu = 1.99\pi$ es mucho más parecido a $\mu = 0$ de que lo es $\mu = \pi$ aunque en el segmento de recta este último esté más cercano. Entonces sería más conveniente decir que la naturaleza -o topología- de μ es la de un círculo y no la de un segmento de recta.

Básicamente, a lo que me vengo refiriendo como “naturaleza de los espacios” es la noción de similitud o continuidad que tienen los parámetros. El área matemática en la que se estudian estas nociones de continuidad se llama topología y es de mucha utilidad para imaginar el lugar donde estamos haciendo inferencia.

Aunque por sí sola, la teoría abstracta de topología no es muy útil para estos fines. Estos es porque se puede hablar de topología sin una noción de distancia. Si podemos complementar la topología de un espacio de parámetros con una noción de distancia entonces la podemos estudiar

¹Esta distribución representa como sería una gaussiana pero para puntos de un círculo

con otra teoría matemática llamada geometría diferencial riemanniana². Esta teoría tiene un lugar muy particular en aplicaciones avanzadas de Machine Learning y puede usarse con cierta facilidad para hacer *feature engineering* también en contextos de aprendizaje automático.

2.2 Distribuciones conjugadas

Como dijimos anteriormente una típica elección de priori es la uniforme por su facilidad en la manipulación algebraica. Esta elección puede ser problemática porque hay veces que eso implica que la distribución $P(\theta)$ no sea normalizable. Esto lo podemos solucionar de dos formas. La primera es anular la distribución de probabilidad sobre valores que consideremos extremos según el contexto. La segunda es decir: *“Bueno, igual esta distribución solo era mi grado de creencias sobre θ , no la necesito normalizada ya que no se puede repetir el experimento y evaluarla con un criterio frecuentista”*.

En este contexto y bajo estas suposiciones el cálculo de la posteriori se reduce a

$$P(\theta|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} P(\mathbf{x}|\theta) \quad (2.11)$$

donde $Z(\mathbf{x})$ normaliza a la distribución de probabilidad. Nuevamente, esta situación es muy típica en contextos de inferencia, lo que motiva la siguiente definición.

Definición 11 Si $P(\cdot|\theta)$ es una distribución de probabilidad que depende de los parámetros $\theta \in \Theta$ y toma valores en $\mathbb{X}$. Dado $\mathbf{x} \in \mathbb{X}^N$, se define la **distribución conjugada** de P como la distribución de probabilidad sobre Θ

$$g(\theta|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} P(\mathbf{x}|\theta), \quad (2.12)$$

donde $Z(\mathbf{x})$ es la constante de normalización de la distribución.

En esencia, la distribución conjugada es una distribución cuyos parámetros son los resultados de las mediciones y va a coincidir con la posteriori cuando la priori sea uniforme.

²Que es la teoría matemática detrás de la relatividad general

2.2.1 Ejemplos de distribuciones conjugadas

Distribución de Bernoulli

Al fin, nos dedicamos a resolver el ejemplo de la moneda. Con el fin de hacer de determinar su parámetros hacemos un muestreo de N variables Bernoulli, $X_i \sim \text{Bern}(p)$. Guardamos los resultados en $\mathbf{x} = (x_1, \dots, x_N)$. La distribución conjugada es entonces

$$g(p|\mathbf{x}) = \frac{1}{Z(\mathbf{x})} \text{Bern}(\mathbf{x}|p) = \frac{1}{Z(\mathbf{x})} p^n (1-p)^{N-n}, \quad (2.13)$$

donde $n = \sum x_i$.

Aunque nos falte la constante de normalización Z nada nos impediría pensar por ejemplo en los estimadores MAP -si tenemos una priori- o ML -si no. En ese sentido, esta constante de normalización no nos aportaría nada más que lograr una distribución de probabilidad que sea proporcional a la verosimilitud. Su cálculo está dado por

$$Z(\mathbf{x}) = \int_0^1 p^n (1-p)^{N-n} dp, \quad (2.14)$$

lo que lleva al resultado

$$g(p|\mathbf{x}) = \binom{N}{n} p^n (1-p)^{N-n} \quad (2.15)$$

Este es un caso particular de la llamada distribución Beta, dada por

$$B(p|\alpha, \beta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} p^{\alpha-1} (1-p)^{\beta-1} \quad (2.16)$$

donde $p \in [0, 1]$, los hiperparámetros $\alpha, \beta \in \mathbb{R}^+$ y la función Γ^3 está dada por

$$\Gamma(x) = \int_0^\infty t^{x-1} e^{-t} dt. \quad (2.17)$$

Distribución Gaussianiana

La distribución normal depende de dos parámetros. Estos significa que vamos a tener una distribución conjugada diferente dependiendo cual de estos sepamos.

³Esta función es muy conocida y se llama función Gamma. Es conocida por ser una generalización de la función factorial a números reales pues $x \in \mathbb{N}_0$ entonces $\Gamma(n+1) = n!$

Si conocemos la desviación estándar y desconocemos la media,

$$g(\mu|\mathbf{x}) \propto \prod \exp\left(-\frac{(\mu - x_i)^2}{2\sigma^2}\right) \propto \exp\left(-\frac{(\mu - \bar{x})^2}{2\sigma^2}\right). \quad (2.18)$$

De esta proporcionalidad se deduce que la conjugada -cuando conocemos la desviación estándar, de la distribución normal es también una normal de la misma varianza.

2.2.2 Distribución Poissoniana

La distribución poissoniana es de la más útiles en lo que se refiere al modelado probabilístico. Algunos ejemplos de sus aplicaciones pueden ser: la cantidad de compras en un día/semana/año, la cantidad de clientes de un negocio, la cantidad de accidentes de transito, los picos de tensión de una neurona y las manchas de un dalmata. Supongamos que queremos inferir el parámetro γ de una distribución poissoniana,

$$p(n|\lambda) = \frac{\lambda^n}{n!} e^{-\lambda} \quad (2.19)$$

Por tanto buscamos la distribución que satisface

$$g(\lambda|\mathbf{n}) \propto e^{-N\lambda} \lambda^{n_1 + \dots + n_N}. \quad (2.20)$$

Calculando la constante de proporción se obtiene una distribución Gamma,

$$g(\lambda|\mathbf{n}) = \frac{N^{n+1}}{(n_1 + \dots + n_N)!} e^{-N\lambda} \lambda^{n_1 + \dots + n_N} \quad (2.21)$$

2.3 Actualización secuencial: el posterior de hoy es la priori de mañana

Es cierto que la probabilidad condicional se define considerando dos eventos. Sin embargo, es la cosmovisión bayesiana lo cierto es que siempre pretendemos actualizar todas nuestras expectativas frente a nueva evidencia, no solo la de un evento específico.

Teorema 2 Sea $(\mathbb{X}, \Sigma, P)$ un espacio de probabilidad y $\Omega \in \Sigma/P(A) \neq \emptyset$. Definimos una función $P_\Omega : \Sigma \rightarrow \mathbb{R}$ según

$$P_\Omega(\cdot) = P(\cdot|\Omega). \quad (2.22)$$

Luego $(\mathbb{X}, \Sigma, P_\Omega)$ es también un espacio de probabilidad.

2.3. ACTUALIZACIÓN SECUENCIAL: EL POSTERIOR DE HOY ES LA PRIOR

Demostración: Como $\mathbb{X}$ es un conjunto y Σ un espacio de eventos solo queda ver que P_Ω satisface los axiomas de Kolmogorov para comprobar que $(\mathbb{X}, \Sigma, P_\Omega)$ es un espacio de probabilidad.

•

$$P_\Omega(\mathbb{X}) = \frac{P(\mathbb{X} \cap \Omega)}{P(\Omega)} = \frac{P(\Omega)}{P(\Omega)} = 1.$$

- Dado $A \in \Sigma$, Luego $A \cap \Omega \in \text{Sigma}$. Como P es una distribución de probabilidad tanto $P(\Omega)$ como $P(A \cap \Omega)$ son mayores a 0. Esto lleva a que su cociente también lo sea,

$$P_\Omega(A) = \frac{P(A \cap \Omega)}{P(\Omega)} \geq 0.$$

- Si tenemos una familia de eventos disjuntos A_i con $i \in I$. También lo va a ser la familia de conjuntos $B_i = A_i \cap \Omega$. Por lo que, usando el tercer axioma de probabilidad de P .

$$P_\Omega\left(\bigcup_{i \in I} A_i\right) = \frac{P(\bigcup_i B_i)}{P(\Omega)} = \frac{\sum_i P(B_i)}{P(\Omega)} = \sum_i P_\Omega(B_i)$$

QED

Lo que significa este resultado es que luego de actualizar nuestras expectativas con las respectivas definiciones seguimos teniendo una función de expectativas consistentes algebraicamente. O sea, podríamos olvidarnos de la notación $P(\cdot|\Omega)$ cambiando la función P entera y tendríamos una función de probabilidad actualizada a nuestras creencias actuales.

Supongamos que queremos hacer inferencia de parámetros θ y para eso hacemos una tanda de mediciones con resultados $x_1, \dots, x_n$. De ello actualizamos nuestras creencias

$$P_{\mathbf{x}}(\theta) = P(\theta|\mathbf{x}) = \frac{P(\mathbf{x}|\theta)P(\theta)}{P(\mathbf{x})}. \quad (2.23)$$

Luego realizamos otras mediciones $y_1, \dots, y_m$. Ahí tenemos que actualizar nuestras creencias pero utilizando de priori la última probabilidad,

$$P_{\mathbf{x}}(\theta|\mathbf{y}) = \frac{P_{\mathbf{x}}(\mathbf{y}|\theta)P_{\mathbf{x}}(\theta)}{P_{\mathbf{x}}(\mathbf{y})}, \quad (2.24)$$

Desarrollando esta expresión obtenemos

$$P_{\mathbf{x}}(\theta|\mathbf{y}) = P(\theta|\mathbf{x}, \mathbf{y}). \quad (2.25)$$

Esto quiere decir que al actualizar nuestras creencias nuevamente podemos usar la primera priori y actualizar con todas las mediciones juntas. Como bien podríamos actualizar la priori una segunda vez en virtud del teorema de Bayes. Esto justificaría olvidarnos de las primeras mediciones y guardar su información en una priori actualizada.

Chapter 3

Introducción a Teoría de Información

En 1948 Shannon publica un trabajo llamado “A mathematical theory of communication”. En este Shannon intenta resolver un problema fundamental de las comunicaciones:

Para reducir la probabilidad de error al enviar un mensaje lo más simple es repetirlo. Y de repetirlo infinitas veces el error tiende a 0 ¿Es posible hacer algo mejor que esto?

En este trabajo, Shannon demuestra que hay maneras mucho más eficientes de transmitir mensajes sin probabilidad de error. Ese logro lo motiva a publicar un libro el año siguiente junto a Warren Weaver con el nombre de “The mathematical theory of communication”. Es decir, asciende su obra de decir que es una teoría a decir que es *la teoría* de la comunicación.

Evidentemente este problema de las telecomunicaciones no es el interés de estas notas. Sin embargo lo que es increíble es como esta teoría resultó de gran utilidad en áreas muy diversas: informática, inferencia estadística (que si nos interesa), física, neurociencias, música, biología, finanzas, etc. Es realmente poco razonable lo útil que resultó esta teoría sujeto a que nació de resolver un problema de ingeniería muy concreto. Nosotros nos vamos a centrar en las aplicaciones de esta a probabilidad, inferencia estadística y Machine Learning.

Si bien la teoría de información está desarrollada tanto en variables aleatorias discretas como continuas -y con formulas muy similares- hay

diferencias conceptuales que hacen que se tengan que estudiar teóricamente de forma diferente. Estas diferencias no son superfluas y tienen consecuencias muy relevantes. De hecho, se suele decir que la definición para variables aleatorias continuas “no funciona tan bien”, lo que motivó que hayan aparecido muchas alternativas a esta.

3.1 La entropía de Shannon

Las definiciones fundamentales de esta teoría se pueden motivar de muchas formas. Una de ellas es la planteada por Shannon en su trabajo original. Esta consiste en pedir ciertas propiedades que pretendemos que siga una noción de información como función de distribuciones de probabilidad definida en un conjunto de símbolos.

En esencia, lo que queremos hacer es armar una función H que reciba una distribución de probabilidad discreta y nos diga “la cantidad de información media que nos daría medirla”. Supongamos que tenemos una variable aleatoria X que toma valores en un alfabeto $\{a_1, \dots, a_n\}$ con distribución de probabilidad $p_1, p_2, \dots, p_n$. Luego vamos a pedir que H satisfaga las siguientes propiedades:

1. H es una función continua de los valores p_i . Porque en principio distribuciones muy similares deberían aportar cantidades similares de información.
2. Si todos los p_i son iguales, entonces H tiene que ser una función monotonamente creciente de n . Si tenemos eventos equiprobables y aumentamos la cantidad de decisiones posibles, entonces la información debería ser mayor.
3. Si un resultado puede descomponerse en dos sucesivos, entonces H debería ser la suma pesada de estos.

Teorema 3 *La única función H que satisface estas propiedades tiene la forma*

$$H = -K \sum_{i=1}^n p_i \log p_i \quad (3.1)$$

con $K \in \mathbb{R}^+$.

Esto motiva la definición de entropía. Un mito interesante sobre esta ecuación es que cuando Shannon la desarrolló no sabía que nombre pon-

erle. Y en una conversación con Jhon von Neumann este le sugirió llamarla “entropía” ya que la forma era igual a aquella de la física estadística ¹ y que a esta última nadie la entendía muy bien.

Definición 12 *Dada una variable aleatoria X que toma valores en el alfabeto $\mathcal{A} = \{a_1, \dots, a_n\}$ con probabilidades $p(a_i) = p_i$. Se define su entropía como*

$$H(X) = - \sum_i p_i \log_a p_i, \quad (3.2)$$

donde a es un real mayor a 1. La elección más típica es $a = 2$, y en este caso la unidad con la que se mide la entropía es el **bit**.

Una aclaración importante es que la entropía no es una función de los resultados posibles, es una función de la distribución de probabilidad entera. Pero también es común encontrar la siguiente definición.

Definición 13 *Dada una variable aleatoria X que toma valores en el alfabeto $\mathcal{A} = \{a_1, \dots, a_n\}$ con probabilidades $p(a_i) = p_i$. La información de a_i está dada por*

$$H(a_i) = -\log_a p_i. \quad (3.3)$$

Con esta definición, la entropía se reduce al valor medio de la información que obtenemos de medir la variable aleatoria.

Ejemplo 1 *Sea $X \sim \text{Ber}(p)$. Calcule $H(X)$. Encuentre su máximo como función de p . Grafique $H(X)$ como función de p . Solución:*

Usando la ecuación (3.2), la entropía la calculamos como

$$H(X) = HB(p) = -p \log_2 p - (1-p) \log_2 (1-p). \quad (3.4)$$

Para encontrar su máximo derivamos HB respecto a p ,

$$HB'(p) = -\log_2 p - \frac{1}{\ln 2} + \log_2 (1-p) + \frac{1}{\ln 2} = -\log_2 \frac{p}{1-p}. \quad (3.5)$$

Entonces de haber un máximo p^ debe satisfacer $HB'(p^*) = 0$. Esto implica que p^* debería ser necesariamente $1/2$. Con el criterio de la derivada segunda se puede ver que es efectivamente un máximo. En la figura 3.1 se grafica la función HB y se puede corroborar lo deducido.*

Podemos ver que cuando la variable aleatoria es uniforme se alcanza el máximo de entropía. Esto no es una particularidad de la distribución de Bernoulli, sino de la entropía en general.

¹Es aquella famosa fórmula pochoclera que de alguna manera mide el “caos”.




Figure 3.1: Entropía de una variable de Bernoulli.

Teorema 4 *Dada X una variable aleatoria que toma valores en $\{a_1, \dots, a_n\}$ con distribución $p_1, \dots, p_n$. Siempre vale que*

1. *No negativa,*

$$H(X) \geq 0 \quad (3.6)$$

2. *La entropía se anula si y solo si X es determinista*

3. *La entropía está acotada por el logaritmo de la cantidad de elementos,*

$$H(X) \leq \log n \quad (3.7)$$

y esta cota máxima se alcanza si y solo si la distribución de probabilidad es uniforme.

4. *Si definimos otra variable aleatoria $Y = f(X)$ con f una función biyectiva,*

$$H(Y) = H(X). \quad (3.8)$$

Esto significa que la entropía no cambia si cambiamos los valores que toma el alfabeto o renombramos sus elementos.

Todas estas propiedades son lo que uno esperaría de una buena noción de información. Primero, obviamente la información no puede ser negativa. Segundo, si yo sé el resultado de una variable aleatoria entonces medirla

no me transmitiría ninguna información. Tercero, la situación donde más información obtendría de medir la variable aleatoria es cuando no sé nada de ellas al punto de que me son indistinguibles. Cuarto, cambiar el nombre del alfabeto no va a cambiar la información que obtenga. Da lo mismo si las respuestas posibles son 1, 2 o 3 o si son a , b o c siempre y cuando la estructura de probabilidades sea la misma.

3.1.1 La entropía como número de preguntas bien elegidas

Otra interpretación muy típica es pensar que la entropía -de base 2- es el número medio de preguntas binarias -bien elegidas- que necesitamos para determinar unívocamente el valor de la variable aleatoria. Se puede demostrar matemáticamente que si todas probabilidades son potencias enteras de $1/2$, entonces si elegimos bien las preguntas binarias la media de preguntas que necesitemos va a coincidir con la entropía. Y en caso de no tener probabilidades que no sean potencias de $1/2$, entonces la media de preguntas que vamos a necesitar está acotado superiormente por la entropía más 1.

3.1.2 Entropía conjunta y condicional

La teoría necesita también definiciones asociadas a cuando hay más de una variable aleatoria en juego.

Definición 14 *Dadas dos variables aleatorias X y Y que toman valores $\{x_1, \dots, x_n\}$ y $\{y_1, \dots, y_m\}$ respectivamente. Se define su **entropía conjunta** como la cantidad*

$$H(X, Y) = - \sum_{i,j}^{n,m} p(x_i, y_j) \log p(x_i, y_j). \quad (3.9)$$

*Se definen las **entropías condicionales** como las cantidades*

$$H(Y|X) = - \sum_i p(x_i) \sum_j p(y_j|x_i) \log p(y_j|x_i). \quad (3.10)$$

En esencia, la entropía conjunta se puede interpretar como la cantidad de preguntas necesarias para determinar simultáneamente los valores que toman X e Y .

Si determinamos primero el valor de X , debemos actualizar bayesianamente la distribución de probabilidad sobre Y . Entonces para cada resultado de X vamos a tener una entropía de Y diferente, luego, la media de entropía de Y por haber determinado primero X es su entropía condicional.

Teorema 5 *Dadas X e Y variables aleatorias. Se puede demostrar que*

1. *Regla de la cadena:*

$$H(X, Y) = H(X) + H(Y|X) \quad (3.11)$$

2. *Condición de independencia: La independencia probalística de X e Y es equivalente a cualquiera de las siguientes ecuaciones*

$$H(X|Y) = H(X) \quad H(Y|X) = H(Y) \quad (3.12)$$

y

$$H(X, Y) = H(X) + H(Y) \quad (3.13)$$

Ambas propiedades tienen interpretaciones muy interesantes. En primer lugar, la regla de la cadena lo que nos dice es que la información de determinar X e Y es la información de determinar X más la de Y sabiendo ya X .

Y lo que nos dice la condición de independencia es que saber Y no nos ahorra ninguna pregunta sobre X si son independientes. Y además la información de determinar X e Y en ese caso es la misma que necesitaríamos de determinar X e Y por separado.

3.2 La divergencia KL y la información mutua

3.2.1 La divergencia KL

Supongamos que queremos determinar el valor de una variable aleatoria X . Nosotros creemos que la distribución que sigue es p_i . Por lo tanto armamos nuestro arbol de probabilidades para que determinar a_i nos cueste (aproximadamente) $H(a_i) = -\log p_i$ preguntas. Sin embargo, la distribución que sigue X no es p_i , sino q_i . Entonces al intentar obtener

el valor que toma X la vamos a meter en el árbol equivocado. El número medio de preguntas que vamos a necesitar es

$$-\sum_i q_i \log p_i.$$

Esta cantidad es muy relevante en ML con lo que merece su propio nombre.

Definición 15 *Dada una variable aleatoria X que toma valores $\{a_1, \dots, a_n\}$. Sean p_i (supuesta distribución) y q_i (distribución real) distribuciones de probabilidad sobre el alfabeto. Definimos la **entropía cruzada** o **Cross-Entropy** entre p_i y q_i como*

$$H(q, p) = -\sum_i q_i \log p_i. \quad (3.14)$$

Hay que admitir que la notación confunde a la entropía cruzada con la entropía conjunta. Pero si nos fijamos que los argumentos que recibe la entropía conjunta son dos variables aleatorias diferentes mientras que en la entropía cruzada son distribuciones de probabilidad posibles sobre una misma variable aleatoria.

Otra pregunta relevante puede ser cuantas preguntas estamos desperdiciando por haber confundido la variable aleatoria. La cuenta entonces sería

$$\langle \text{Preguntas desperdiciadas} \rangle = \langle \text{Preguntas hechas} \rangle - \langle \text{Preguntas necesarias} \rangle.$$

Identificando las preguntas hechas como la entropía cruzada y las que realmente necesitamos como la entropía se motiva la siguiente definición.

Definición 16 *Se define la **divergencia de Kullback-Leibler** entre p y q como la cantidad,*

$$D_{KL}(p||q) = \sum p_i \log q_i + \sum p_i \log p_i = \sum p_i \log \frac{p_i}{q_i}. \quad (3.15)$$

Teorema 6 *Dadas p_i y q_i distribuciones sobre el mismo alfabeto. Esta cantidad siempre es no negativa*

$$D_{KL}(p||q) \geq 0 \quad (3.16)$$

y se anula si y solo si $p_i = q_i$.

Este último teorema nos remarca una obviedad: hay que armar el árbol con la distribución real para no desperdiciar preguntas.

Esta cantidad es muy relevante para hacer comparaciones entre distribuciones de probabilidad definidas en el mismo alfabeto. Sin embargo, no constituye lo que se llama una “*métrica*” en el sentido matemático porque no cumple las propiedades necesarias -como la conmutatividad. Además si p está definida en un punto donde q , la divergencia KL diverge irremediabilmente.

3.2.2 Uso de Cross-Entropy en contextos de ML

En contextos de ML aplicado a problemas de clasificación es muy común utilizar como función de pérdida a la entropía cruzada. En este caso toma el nombre de **Cross-Entropy Loss**.

Supongamos que estamos entrenando un clasificador con K etiquetas. Este recibe una entrada $\mathbf{x}$ que puede ser de cualquier naturaleza. Dependiendo el tipo de clasificación la entrada se va a someter a una serie de transformaciones que notamos. Luego, por cada etiqueta va a haber una función $f_k(\mathbf{x})$ que nota “*cuanto de la etiqueta k hay en la salida*”. Pero lo más común es pretender que haya una probabilidad por etiqueta, no solamente un número. Para ello se realiza una transformación más,

$$p_k(\mathbf{x}) = \frac{\exp(f_k(\mathbf{x}))}{\sum \exp(f_k(\mathbf{x}))}. \quad (3.17)$$

A esta transformación se le suele denominar **Soft min-max**.

Luego, suponiendo que la distribución de probabilidad real es q , la entropía cruzada (usando el logaritmo natural) queda

$$H(q, p) = \sum q_k \ln p_k = \sum q_k \left(f_k - \ln \left(\sum_i \exp(f_i) \right) \right)$$

y como la suma de los f_k no depende de k y los q_k deben estar normalizados,

$$H(q, p) = \sum_k q_k f_k - \ln \left(\sum_k \exp(f_k) \right). \quad (3.18)$$

Notemos que optimizar la forma de f para minimizar la entropía cruzada coincide con minimizar la divergencia KL . Esto se debe a que el término que agrega la divergencia es independiente de f , solo depende de la distribución q_k .

En la figura 3.2 se esquematiza el uso del *Soft MinMax* y de la *Cross-Entropy Loss* en un modelo de clasificación con aprendizaje supervisado.




Figure 3.2: Esquema de un modelo optimizado usando la Cross-Entropy Loss.

3.2.3 La información mutua

Otra cantidad profundamente relevante es la que proviene de preguntarnos cuántas preguntas sobre X nos ahorramos por saber Y .

Definición 17 Dadas dos variables aleatorias X e Y se define su **información mutua** $I(X; Y)$ como

$$I(X; Y) = H(Y) - H(Y|X). \quad (3.19)$$

Teorema 7 La información mutua es conmutativa y dadas variables aleatorias X e Y satisface

$$I(X; Y) = H(Y) - H(Y|X) = H(X) - H(X|Y) \quad (3.20)$$

$$I(X; Y) = H(X) + H(Y) - H(X, Y) = D_{KL}(p(x, y) || p(x)p(y)) \quad (3.21)$$

Este último teorema nos indica dos cosas:

1. Las preguntas que nos ahorramos de X por saber Y son las mismas que nos ahorramos de Y por saber X .
2. La información mutua entre dos variables aleatorias es la misma que la cantidad de preguntas que desperdiciaríamos por suponer independientes a las variables aleatorias.

Y nuevamente, realizamos una definición para el caso condicionado

Definición 18 *Dadas variables aleatorias X, Y, Z , definimos la **información mutua condicionada** $I(X, Y|Z)$ como*

$$H(X; Y|Z) = H(X|Z) + H(Y|Z) - H(X, Y|Z). \quad (3.22)$$

Teorema 8 *Algunas propiedades asociadas a la información mutua son*

1.

$$I(X, X) = H(X) \quad (3.23)$$

2. *Conmutatividad,*

3. *No negatividad,*

$$I(X, Y) \geq 0 \quad (3.24)$$

con la igualdad valiendo si y solo si las variables son independientes.

4. *Acotada superiormente,*

$$I(X, Y) \leq \min(H(X), H(Y)) \quad (3.25)$$

3.3 La desigualdad del procesamiento de datos

Una de las conclusiones más relevantes sobre teoría de información es la llamada desigualdad del procesamiento de datos. Básicamente consiste en pensar un sistema muy sencillo: Tenemos una variable aleatoria X de la cual queremos saber el resultado pero no la vemos directamente. Sino, que la medimos con algún instrumento cuyo resultado es la variable aleatoria Y de la cual sabemos las probabilidades $p(y|x)$. Puede ser que la variable X tenga un valor e Y la intenta leer pero sometida a cierto ruido por ejemplo. Entonces la información que obtenemos sobre X con

estas mediciones es cuanto se reduce la entropía de X al saber Y . Esto se cuantifica como la información mutua entre X e Y .

Puede surgir la pregunta de si podemos hacer algún análisis de datos de Y para mejorar esta información mutua. Llamamos Z al resultado de análisis de datos, que puede ser tanto determinista como probabilístico. Como es un análisis de datos tenemos la estructura condicional $p(z|y)$. Pero es muy importante considerar que nuestro análisis de datos solo puede “ver” a la variable aleatoria Y , nunca a la X directamente. Esto se codifica matemáticamente con la siguiente ecuación

$$p(z|x, y) = p(z|y). \quad (3.26)$$

Es decir, si sabemos el valor de y , no puede impactar en el análisis de datos el valor real de x . Esto no quiere decir que z sea independiente de x . De hecho, el valor de X induce una probabilidad en la distribución de los Y que induce una diferente en la de los Z . Pero una vez tenemos el valor de Y resultante, como Z solo mira el valor de esta y no el de X , no puede haber una dependencia con este último en lo que respecta a nuestro análisis. Este estilo de estructura se conoce como independencia condicional.

Entonces la pregunta sería

¿Es mayor la información mutua entre X y Z que la de X e Y ?

Para responderla planteamos la siguiente información mutua:

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) = I(X; Z) + I(X; Y|Z) \quad (3.27)$$

Aplicando la ecuación (3.26) vemos que $I(X; Z|Y) = 0$. Y como $I(X; Y|Z)$ es siempre mayor o igual a 0, debe darse que

$$I(X; Y) \geq I(X; Z). \quad (3.28)$$

Esta desigualdad nos dice algo fundamental sobre el análisis de datos:

No podemos ganar información sobre lo que estamos midiendo solo analizando datos.

Es fácil reaccionar a la defensiva frente a esta desigualdad y preguntarse para qué analizar los datos entonces. Y es que lo importante de entender es que, que haya más información no implica que esta sea fácil de entender o que habilite el proceso de inferencia con mayor facilidad. Y es precisamente esto lo que hacemos los datos que analizamos, los

transformamos hasta que nosotros -o una computadora- podamos entenderlos facilmente pero bajo ningún concepto estamos haciendo aparecer información nueva. De hecho, en el mejor de los casos, no perdemos información.

Los análisis o transformaciones donde no perdemos información son muy relevantes. Y son de particular interés aquellos donde la entropía de la variable final es menor por tener menos elementos sin perder información sobre la primer variable.

Definición 19 Sean dos variables aleatorias X e Y definimos una tercera $Z = f(Y)$, es decir, Z es un análisis de datos determinista de Y . Decimos que el mapeo f constituye una estadística suficiente si

$$I(X, Y) = I(X, Z). \quad (3.29)$$

3.4 Teoría de información para distribuciones continuas

En analogía al caso discreto, se define la entropía diferencial como una cantidad que representa la información otorgada por medir variables aleatorias continuas.

Definición 20 Sean X una variable aleatoria continua con densidad de probabilidad p . Se define la **entropía diferencial** de X como la cantidad

$$h(X) = - \int p(x) \ln p(x) dx. \quad (3.30)$$

Y por supuesto todas las definiciones que se desprenden de la entropía discretas las adaptamos cambiando la sumatoria por una integral donde corresponda.

A pesar de que el cambio de la sumatoria por integral parezca muy razonable, vamos a hacer las cuentas con más cuidado discretizando el caso continuo y usando en el la fórmula de Shannon discreta. Supongamos que dividimos el intervalo continuo donde se define la distribución de probabilidad en subintervalos de grosor Δ . Si los intervalos son suficientemente pequeños, la probabilidad de que salga cada uno de ellos es $p(x)\Delta$. Por tanto, usando la entropía discreta,

$$H(X) = - \sum p(x)\Delta \log(p(x)\Delta)$$

$$= - \underbrace{\sum p(x)\Delta \log p(x)}_{\rightarrow h(X)} - \underbrace{\sum p(x)\Delta \log \Delta}_{\rightarrow \infty}.$$

Cuando tendemos $\Delta \rightarrow 0$ se puede pensar que $\sum \Delta \rightarrow \int$. Y así el primer término tiende a la entropía diferencial y el segundo diverge.

Esto significa que la entropía diferencial no es una extensión natural de la entropía discreta. Pues la entropía diferencial es la discreta con un infinito tachado. Y debido a tachar esta divergencia se pierden muchas propiedades del caso discreto. Detallamos algunas de estas pérdidas teóricas en la siguiente proposición.

Teorema 9 *Dada X una variable aleatoria continua.*

1. $h(X)$ no está acotada inferiormente. Es decir, puede ser negativa.
2. $h(X)$ no siempre está acotada superiormente. Cuando los valores que puede tomar la entropía está acotado a una región de volumen V , luego tiene una cota máxima dada por

$$h(X) \leq \log(V) \tag{3.31}$$

que se alcanza si y solo si la distribución es uniforme.

3. Si X tiene unidades la entropía va a tener un logaritmo de unidades sumado.
4. La entropía diferencial no es invariante a cambios de coordenadas o transformaciones biyectivas. Esto es que si $Y = f(X)$ con f una función biyectiva no necesariamente vale que $h(Y) = h(X)$.

Sin embargo, no todas las cantidades tienen un paso al continuo tan desagradable. Muchas, al depender de una resta, conservan mejor propiedades pues los infinitos se restan mutuamente llegando a resultados del caso discreto reemplazando sumas por integrales. Este es el caso de la información mutua y de la divergencia KL.

3.5 La información de Fisher

Supongamos que tenemos una distribución de probabilidad X que depende de parámetros θ . Queremos calcular cuanto cambia la distribución

al variar estos parámetros diferencialmente. Para ello vamos a usar la divergencia KL.

$$D_{KL}(p(\theta)||p(\theta + d\theta)) = - \left\langle \log \left(\frac{p(x|\theta + d\theta)}{p(x|\theta)} \right) \right\rangle$$

Aproximando a primeros ordenes

$$p(x|\theta + d\theta) \approx p(x|\theta) + \frac{\partial p(x|\theta)}{\partial \theta} d\theta + \frac{1}{2} \frac{\partial^2 p(x|\theta)}{\partial \theta^2} d\theta^2 \quad (3.32)$$

y

$$\ln(1 + x) \approx 1 + x - \frac{1}{2} x^2 \quad (3.33)$$

llegamos a que

$$D_{KL}(p(\theta)||p(\theta + d\theta)) = \frac{1}{2} \left\langle \left(\frac{\partial \log p(x|\theta)}{\partial \theta} \right)^2 \right\rangle d\theta^2 = \frac{1}{2} J(\theta) d\theta^2 \quad (3.34)$$

donde $J(\theta) = \left\langle \left(\frac{\partial \log p(x|\theta)}{\partial \theta} \right)^2 \right\rangle$.

De acá podemos ver detalles de cierta relevancia. Sumar $d\theta$ de un lado es lo mismo que restar $d\theta$ del otro. Pero como en la ecuación aparece este diferencial al cuadrado implica que D_{KL} conmuta en cercanías. Esto lo acerca a una noción de distancia (que precisamente requiere esta conmutabilidad). Esto nos motiva a definir la siguiente cantidad

Definición 21 *Dada una variable aleatoria dependiente de una distribución de probabilidad paramétrica dependiente de n parámetros continuos $\theta^1, \dots, \theta^n$, definimos su **información de Fisher** como*

$$J(\theta)_{\mu\nu} = \left\langle \frac{\partial \log p(x|\theta)}{\partial \theta^\mu} \frac{\partial \log p(x|\theta)}{\partial \theta^\nu} \right\rangle. \quad (3.35)$$

Teorema 10 *La información de Fisher puede calcularse como*

$$J(\theta)_{\mu\nu} = - \left\langle \frac{\partial^2 \ln p(x|\theta)}{\partial \theta^\mu \partial \theta^\nu} \right\rangle. \quad (3.36)$$

3.5.1 Interpretación geométrica de la información de Fisher

Suele ser de utilidad contar con una noción de distancia entre configuraciones de parámetros de distribuciones. Tarea para la que la divergencia KL falló por carecer de la propiedad conmutativa.

Supongamos que queremos medir la media de una distribución normal. Supongamos que el valor real es $\mu_0 = 0$, pero nosotros medimos μ_1 ¿Qué tan grave fue nuestro error? Bueno, una manera bastante efectiva es comparar la diferencia de medias contra la desviación estándar. Por tanto una buena noción de distancia penalizaría diferencias de la media con más dureza si la desviación estándar es mayor.

Ahora, si queremos medir la media y la desviación estándar. Si los valores reales son (μ_0, σ_0) y los medidos (μ_1, σ_1) ¿Qué criterio aplicamos para dar una distancia entre estos puntos? ¿Diferencias pesadas?

Acá podemos usar a la información de Fisher, que recordamos nos da una noción de qué tanto cambia la distribución al variar los parámetros diferencialmente. Supongamos que tenemos un espacio continuo de parámetros Θ , que pueden tener múltiples dimensiones. Podemos expresar al parámetro según sus coordenadas $\theta = (\theta^1, \dots, \theta^n)$.

Entonces la idea es: armamos una trayectoria desde el punto inicial al final y sumamos los cambios infinitesimales. Sea $\mathbf{r} : [0, 1] \rightarrow \Theta$ una trayectoria diferenciable en el espacio de parámetros tal que

$$\mathbf{r}(0) = \theta_0 \quad \mathbf{r}(1) = \theta_1 \quad (3.37)$$

donde θ_0 y θ_1 son los parámetros iniciales y finales de la trayectoria. Podemos definir la longitud de la trayectoria, usando la información de Fisher como

$$\int_0^1 \sqrt{\sum_{\mu\nu} J_{\mu\nu}(\theta) \frac{dr^\mu}{dt} \frac{dr^\nu}{dt}} dt. \quad (3.38)$$

Esta noción de distancia está definida como la suma de cambios por ir aumentando diferencial a diferencial la divergencia KL entre puntos de la trayectoria.

Pero no definimos distancia entre puntos, definimos longitudes de trayectorias. Para definir la distancia entre dos configuraciones de parámetros, tomamos la menor longitud posible de todas las trayectorias que los unan.

Ahora si contamos con una noción de distancia entre configuraciones alejadas.

3.5.2 La cota de Cramer-Rao

Chapter 4

Regresiones en contextos bayesianos

Chapter 5

Modelos jerarquicos

Chapter 6

MCMC y Programación probabilística

Chapter 7

Redes neuronales bayesianas

Chapter 8

Optimización Bayesiana

Chapter 9

Distribuciones de probabilidad

9.1 Distribución de Bernoulli. $X \sim \text{Bern}(p)$.

Modela si sucede o no cierto evento.

$$\text{Bern}(x|p) = \begin{cases} p & x = 1 \\ 1 - p & x = 0 \end{cases} = p^x(1 - p)^{1-x} \quad (9.1)$$

$\mathbb{X}$	Mean	Variance	Shannon Entropy	Fisher's Information
$\{0,1\}$	p	$p(1 - p)$	$-p \log p - (1 - p) \log(1 - p)$	$J(p) = \frac{1}{p(1-p)}$

9.2 Distribución Binomial. $X \sim \text{Bin}(p, N)$.

Es la suma de N variables de Bernoulli. Es fácil de entender como "la cantidad de éxitos" cuando un evento se intenta N veces con probabilidad p .

$$\text{Bin}(n|p) = \binom{N}{n} p^n (1 - p)^{N-n} \quad (9.2)$$

$\mathbb{X}$	Mean	Variance
$\{0,1,\dots,N\}$	Np	$Np(1-p)$

9.3 Distribución Categórica, $\mathbf{X} \sim \text{Cat}(\mathbf{p})$

Es una generalización de todas las variables aleatorias discretas finitas. Puede ser útil para modelar datos categóricos aunque contiene teóricamente al resto de distribuciones donde el orden si representa algo relevante. Es útil pensar que los eventos posibles son

$$\mathbb{X} = \{\mathbf{e}_1, \dots, \mathbf{e}_n\} \quad (9.3)$$

donde $\mathbf{e}_i$ es el i -ésimo vector de la base canónica. Cada uno de ellos tiene una probabilidad disjunta,

$$\text{Cat}(\mathbf{e}_i | \mathbf{p}) = p_i, \quad (9.4)$$

donde los p_i son los parámetros de la distribución, que deben satisfacer que su suma sea igual a 1. Esta distribución entendida así sigue reglas similares a una distribución de Bernoulli

$$\langle \mathbf{X} \rangle = \begin{bmatrix} p_1 \\ p_2 \\ \vdots \\ p_n \end{bmatrix} = \mathbf{p}. \quad (9.5)$$

Su varianza está dada por

$$\langle (\mathbf{X} - \langle \mathbf{X} \rangle)^2 \rangle = \begin{bmatrix} p_1(1-p_1) \\ p_2(1-p_2) \\ \vdots \\ p_n(1-p_n) \end{bmatrix} = \mathbf{p} \odot (1 - \mathbf{p}). \quad (9.6)$$

9.4 Distribución Multinomial, $\mathbf{X} \sim \text{Mult}(N, \mathbf{p})$

Modela la cantidad de veces que aparece cierta categoría cuando se toman N muestras. Es por tanto una suma de variables categóricas. Su distribución es

$$\text{Mult}(\mathbf{n} | N, \mathbf{p}) = \frac{N!}{n_1! n_2! \dots n_N!} p_1^{n_1} \dots p_N^{n_N} = N! \prod_{i=1}^{i=N} \frac{p_i^{n_i}}{n_i!} \quad (9.7)$$

donde n_i es la cantidad de veces que aparece la categoría i y su suma debe ser igual a N . Sus valor medio y varianza es

$$\langle \mathbf{N} \rangle = N\mathbf{p} \quad \langle (\mathbf{N} - \langle \mathbf{N} \rangle)^2 \rangle = N\mathbf{p} \odot (1 - \mathbf{p}) \quad (9.8)$$

9.5 Distribución Uniforme Discreta, $X \sim U(n)$.

Es una distribución que asigna a todos sus n posibles resultados la misma probabilidad. En algún sentido es la distribución fundamental de la interpretación clásica de la probabilidad. Su uso se suele argumentar basandose en la simetría de sus elementos y el no tener una preferencia por alguno. Su distribución es

$$U(i|n) = \frac{1}{n}. \quad (9.9)$$

Una de sus características es que es la distribución discreta de n elementos que maximiza la entropía de Shannon, teniendo un valor de

$$H(U(n)) = \log(n). \quad (9.10)$$

9.6 Distribución de probabilidad hipergeométrica, $X \sim \text{HG}(N, M, n)$

Es la distribución de probabilidad proveniente de hacer un muestreo sin remplazos, por lo que, estrictamente es la distribución que seguirían categorías binarias en una encuesta. Por conveniencia, para esto último se usa sencillamente una distribución binomial. Pero para esta aproximación es necesario que el segmento de población muestreado sea mucho menor que la población total. De no darse esta situación, se debe utilizar esta distribución.

N es el tamaño de la categoría 1,, M el de la categoría 2 y n es la cantidad de meustras realizadas. Debe darse que $n \leq N + M$. Su distribución es

$$\text{HG}(x|N, M, n) = \frac{\binom{M}{x} \binom{N-M}{n-x}}{\binom{N}{n}}. \quad (9.11)$$

9.7 Distribución Geométrica, $N \sim \text{Geo}(p)$

Una distribución de probabilidad muy relevante es la denominada geométrica. Se suele pensar como la cantidad de eventos que hay que intentar hasta que aparezca un éxito de probabilidad p . $\mathbb{X} = \mathbb{N}$ con distribución

$$\text{Geo}(n|p) = p(1-p)^{n-1}. \quad (9.12)$$

Su nombre viene de que cuando se calculan los valores medios muy frecuentemente el cálculo termina con la serie geométrica. Su media está dada por

$$\langle N \rangle = \frac{1}{p} \quad (9.13)$$

y su varianza

$$\sigma^2 = \frac{1-p}{p^2}. \quad (9.14)$$

Su entropía está dada por

$$H(\text{Geo}(p)) = \frac{HB(p)}{p} = -\frac{p \log p + (1-p) \log(1-p)}{p} \quad (9.15)$$

9.8 Distribución de Poisson, $N \sim \text{Poi}(\lambda)$

Es una distribución de probabilidad muy útil para estudiar mucha fenomenología muy variada. Desde cantidad de clientes en un día hasta la cantidad gotas de lluvia que caen en cierta región. Puede verse como un límite de una distribución binomial cuando $N \rightarrow \infty$ y $pN \rightarrow \lambda$, lo que lleva a ser usado como aproximación de la distribución binomial cuando p es pequeño y N grande. A λ se le llama su parámetro o media y da origen a una distribución de la forma

$$\text{Poi}(n|\lambda) = \frac{\lambda^n}{n!} e^{-\lambda}. \quad (9.16)$$

Su media y varianza son ambas

$$\langle N \rangle = \sigma^2 = \lambda. \quad (9.17)$$

Su entropía está dada por

$$H(\text{Poi}(\lambda)) \quad (9.18)$$

Appendix A

Un plus de matemáticas

A.1 Funciones útiles

A.2 Espacios vectoriales

A.3 Espacios métricos